

Preprocessing Data Harga Rumah: Pembersihan, Penanganan Outlier, Transformasi, dan Reduksi Dimensi

Muhammad Irzam Hafis Fabiansyah · 5054251024 · Praktikum 2 Mata Kuliah Data Mining

Abstrak — Kualitas model prediktif sangat bergantung pada kualitas data masukan. Laporan ini mendokumentasikan tahapan *preprocessing* terhadap dataset *House Prices* dari Kaggle yang terdiri atas 1.460 baris dan 81 kolom. Lima kolom dengan nilai hilang di atas 50% dihapus, dan sisa nilai hilang diisi sesuai makna kolomnya berdasarkan dokumentasi dataset. Deteksi outlier dengan boxplot dan aturan IQR menunjukkan bahwa 60% baris memiliki setidaknya satu outlier, sehingga penghapusan massal tidak layak; sebagai gantinya dua baris anomali dihapus dan 12 atribut kontinu disesuaikan dengan *capping*. Atribut numerik distandarisasi dengan z-score dan atribut kategoris di-*encode* dengan one-hot encoding sehingga diperoleh 294 fitur. Analisis korelasi menghapus empat atribut redundan ($|r| > 0,8$), lalu PCA mereduksi 290 fitur menjadi 77 komponen utama yang mempertahankan 95% varians.

Kata kunci: preprocessing, nilai hilang, outlier, standarisasi, one-hot encoding, PCA

1. Pendahuluan

Data dunia nyata jarang siap dipakai langsung untuk pemodelan. Nilai hilang, pencilan, skala atribut yang berbeda jauh, serta atribut kategoris berbentuk teks perlu ditangani terlebih dahulu [1]. Selain itu, jumlah atribut yang besar (terlebih setelah *encoding*) dapat membuat model lambat dan rentan *overfitting*, sehingga reduksi dimensi sering diperlukan.

Dataset yang digunakan adalah `train.csv` dari kompetisi *House Prices – Advanced Regression Techniques* [2], yang berasal dari data penjualan rumah di Ames, Iowa [3]. Setiap baris mewakili satu rumah dengan 79 atribut penjelas (luas, kualitas, tahun dibangun, lokasi, dan sebagainya) serta target `SalePrice`.

2. Metodologi

Seluruh proses dikerjakan dengan Python (Pandas, Matplotlib, Seaborn, scikit-learn) pada notebook `prak2_final.ipynb`.

1. **Import data.** `train.csv` diunduh dengan kagglehub, dibaca dengan Pandas, lalu diperiksa dengan `.head()`, `.shape`, dan `.info()`.
2. **Pembersihan data.** Jumlah nilai hilang dihitung per atribut; atribut dengan proporsi hilang $> 50\%$ dihapus, dan sisanya diisi berdasarkan makna kolom.
3. **Deteksi dan penanganan outlier.** Boxplot dan aturan IQR ($< Q_1 - 1,5 \cdot \text{IQR}$ atau $> Q_3 + 1,5 \cdot \text{IQR}$) dipakai untuk mendeteksi outlier, kemudian ditangani dengan penghapusan selektif dan *capping*.

4. **Transformasi.** Atribut numerik distandarisasi ($z = (x - \mu)/\sigma$) dan atribut kategoris di-*encode* dengan one-hot encoding.
5. **Reduksi dimensi.** Pasangan atribut dengan korelasi Pearson $|r| > 0,8$ dicari dan salah satunya dibuang; kemudian PCA diterapkan dengan jumlah komponen yang menjaga 95% varians.


3. Hasil dan Pembahasan

3.1. Struktur Data

Dataset terdiri atas 1.460 baris dan 81 kolom: 43 kolom bertipe teks, 35 bertipe int64, dan 3 bertipe float64. Kolom Id hanya berfungsi sebagai penanda baris sehingga dibuang, dan SalePrice dipisahkan sebagai target. Tidak ditemukan baris duplikat. Keluaran `.info()` menunjukkan beberapa kolom memiliki jumlah *non-null* jauh di bawah 1.460, yang menandakan adanya nilai hilang.

3.2. Pembersihan Data

Sebanyak 19 atribut memiliki nilai hilang (Gambar 1). Lima di antaranya melewati batas 50% sehingga dihapus: PoolQC (99,5%), MiscFeature (96,3%), Alley (93,8%), Fence (80,8%), dan MasVnrType (59,7%). Menurut dokumentasi dataset, nilai kosong pada kolom-kolom ini sebenarnya berarti “tidak memiliki” (misalnya tidak ada kolam renang), namun karena hampir seluruh rumah tidak memilikinya, informasi yang dibawa sangat sedikit.



Gambar 1. Persentase nilai hilang per atribut; merah menandai atribut yang dihapus


Sisa nilai hilang ditangani sesuai makna kolomnya, bukan dengan satu strategi seragam, seperti dirangkum pada Tabel 1. Setelah langkah ini tidak ada lagi nilai hilang, dan data berukuran 1.460 baris $\times$ 75 kolom.

Atribut	Arti nilai kosong	Penanganan
FireplaceQu, Garage*, Bsmt* (kategoris)	rumah tidak memiliki perapian/garasi/basement	diisi kategori "None"
GarageYrBlt	tidak ada garasi	diisi YearBuilt (nilai 0 akan menjadi outlier ekstrem)
MasVnrArea	tidak ada <i>veneer</i>	diisi 0
LotFrontage (17,7%)	tidak tercatat	median per Neighborhood
Electrical (1 baris)	tidak tercatat	diisi modus

Tabel 1. Strategi penanganan sisa nilai hilang

3.3. Deteksi dan Penanganan Outlier

Sebelum deteksi, MSSubClass diubah menjadi atribut kategoris karena nilainya (20, 60, 120, ...) merupakan kode tipe rumah, bukan besaran. Boxplot untuk 35 atribut numerik ditampilkan pada Gambar 2.



Gambar 2. Boxplot seluruh atribut numerik


Dengan aturan IQR, 870 dari 1.460 baris (60%) memiliki minimal satu outlier. Menghapus semua baris tersebut akan membuang lebih dari separuh data, sehingga tidak layak. Selain itu, sebagian besar “outlier” merupakan nilai yang valid:

- Sembilan atribut memiliki IQR = 0 (PoolArea, MiscVal, ScreenPorch, EnclosedPorch, dll.) karena mayoritas nilainya 0; setiap rumah yang memiliki fitur tersebut otomatis tergolong outlier.


- Atribut diskret/ordinal seperti OverallCond, BedroomAbvGr, dan KitchenAbvGr ditandai outlier padahal nilainya wajar.

Oleh karena itu, penanganan dilakukan dalam tiga bentuk:

1. **Dihapus:** dua rumah dengan GrLivArea > 4.000 sqft tetapi SalePrice < 300.000 (Gambar 3). Rumah ini jauh menyimpang dari tren luas-harga dan merupakan penjualan parsial; pembuat dataset sendiri menyarankan menghapus rumah di atas 4.000 sqft [3].
2. **Disesuaikan (*capping*):** 12 atribut kontinu (LotFrontage, LotArea, MasVnrArea, BsmtFinSF1, BsmtUnfSF, TotalBsmtSF, 1stFlrSF, 2ndFlrSF, GrLivArea, GarageArea, WoodDeckSF, OpenPorchSF) dipotong ke batas IQR. Data tidak hilang, tetapi nilai ekstrem seperti LotArea 215.245 (dipotong ke ≈ 17.683) tidak lagi mendominasi standarisasi dan PCA (Gambar 4).
3. **Dibiarkan:** atribut tahun, atribut diskret/ordinal, dan atribut ber-IQR 0, karena *capping* justru akan merusak informasinya (misalnya PoolArea akan menjadi 0 seluruhnya).



Gambar 3. Hubungan GrLivArea dan SalePrice; titik merah adalah dua baris yang dihapus



Gambar 4. Boxplot atribut kontinu sebelum (atas) dan sesudah (bawah) *capping*

Setelah tahap ini data berukuran 1.458 baris $\times$ 75 kolom.

3.4. Transformasi Data


Standarisasi. Ke-35 atribut numerik ditransformasi dengan z-score sehingga masing-masing memiliki rerata 0 dan simpangan baku 1. Standarisasi dipilih dibanding normalisasi min-max karena (1) PCA bekerja berdasarkan varians sehingga seluruh atribut harus berada pada skala yang sama, dan (2) min-max sangat bergantung pada nilai minimum dan maksimum sehingga lebih sensitif terhadap sisa nilai ekstrem. Target SalePrice tidak ikut ditransformasi.

One-hot encoding. Sebanyak 39 atribut kategoris diubah menjadi kolom biner 0/1 per kategori. Hasilnya 259 kolom *dummy*, sehingga total fitur menjadi 294 (35 numerik + 259 *dummy*). Lonjakan dimensi ini menjadi alasan utama perlunya reduksi dimensi.

3.5. Reduksi Dimensi

3.5.1. Analisis Korelasi

Korelasi Pearson dihitung pada atribut numerik (Gambar 5). Dari setiap pasangan dengan $|r| > 0,8$, atribut yang korelasinya terhadap SalePrice lebih lemah dibuang (Tabel 2).



Gambar 5. Matriks korelasi Pearson atribut numerik setelah standarisasi


Atribut 1	Atribut 2	<i>r</i>	$ r $ terhadap SalePrice	Dibuang
GarageCars	GarageArea	0,894	0,641 / 0,633	GarageArea
YearBuilt	GarageYrBlt	0,845	0,524 / 0,509	GarageYrBlt
GrLivArea	TotRmsAbvGrd	0,834	0,712 / 0,538	TotRmsAbvGrd
TotalBsmtSF	1stFlrSF	0,805	0,640 / 0,624	1stFlrSF

Tabel 2. Pasangan atribut berkorelasi tinggi dan atribut yang dibuang

Keempat pasangan tersebut masuk akal secara domain: garasi yang lebih luas menampung lebih banyak mobil; garasi umumnya dibangun bersamaan dengan rumah (apalagi nilai kosong GarageYrBlt diisi YearBuilt); luas lantai yang lebih besar berarti lebih banyak ruangan; dan basement biasanya berada tepat di bawah lantai pertama dengan luas yang mirip. Setelah langkah ini fitur berkurang dari 294 menjadi 290.


3.5.2. Principal Component Analysis

PCA [4] diterapkan pada seluruh 290 fitur. Kurva kumulatif *explained variance* (Gambar 6) menunjukkan bahwa 77 komponen utama sudah cukup untuk menjelaskan 95% varians data, atau berkurang sekitar 73% dari jumlah fitur sebelumnya.



Gambar 6. Kumulatif *explained variance* terhadap jumlah komponen

Komponen pertama (PC1) menjelaskan 15,5% varians, diikuti PC2 (7,2%) dan PC3 (6,0%). Atribut dengan *loading* terbesar pada PC1 adalah OverallQual (0,313), GarageCars (0,277), YearBuilt (0,276), GrLivArea (0,271), dan FullBath (0,262), sehingga PC1 dapat dimaknai sebagai “ukuran, kualitas, dan kebaruan rumah”. Hal ini terlihat pada Gambar 7, di mana warna harga rumah bergradasi mengikuti sumbu PC1.



Gambar 7. Proyeksi data pada PC1 dan PC2, diwarnai berdasarkan SalePrice

Perlu dicatat bahwa kolom *dummy0/1* memiliki varians yang jauh lebih kecil dibanding atribut numerik terstandarisasi (varians 1), sehingga komponen-komponen awal PCA lebih banyak ditentukan oleh atribut numerik.

4. Kesimpulan

Tahapan *preprocessing* mengubah dataset *House Prices* dari 1.460×81 menjadi matriks 1.458×77 yang bersih, berskala seragam, dan jauh lebih ringkas (Tabel 3).

Tahap	Perlakuan	Ukuran data
Import	membaca <code>train.csv</code>	1.460×81
Pembersihan	hapus 5 atribut > 50% hilang dan Id; imputasi sesuai makna kolom	1.460×75
Outlier	hapus 2 baris anomali; <i>capping</i> IQR pada 12 atribut kontinu	1.458×75
Transformasi	standarisasi z-score; one-hot encoding (target dipisah)	1.458×294
Korelasi	buang 4 atribut dengan $ r > 0,8$	1.458×290
PCA	95% varians dipertahankan	1.458×77

Tabel 3. Ringkasan perubahan data pada setiap tahap

Keputusan penting pada proses ini adalah tidak menangani seluruh nilai hilang dan outlier dengan cara yang sama: makna tiap kolom menentukan apakah nilai kosong berarti “tidak ada” atau “tidak tercatat”, dan apakah sebuah outlier merupakan kesalahan atau variasi yang wajar. Data hasil PCA beserta target *SalePrice* siap digunakan untuk tahap pemodelan regresi.

5. Referensi

- [1] J. Han, M. Kamber, and J. Pei, *Data Mining: Concepts and Techniques*, 3rd ed. Morgan Kaufmann, 2011.
- [2] A. Montoya and DataCanary, “House Prices - Advanced Regression Techniques.” [Online]. Available at: <https://www.kaggle.com/competitions/house-prices-advanced-regression-techniques>
- [3] D. De Cock, “Ames, Iowa: Alternative to the Boston Housing Data as an End of Semester Regression Project,” *Journal of Statistics Education*, vol. 19, no. 3, 2011.
- [4] I. T. Jolliffe and J. Cadima, “Principal Component Analysis: A Review and Recent Developments,” *Philosophical Transactions of the Royal Society A*, vol. 374, no. 2065, p. 20150202, 2016.