Tugas Association Rule — Online Retail

Muhammad Irzam Hafis Fabiansyah — 5054251024

Tujuan: menemukan pola pembelian produk (aturan asosiasi) pada dataset *Online Retail* (UCI) menggunakan algoritma **FP-Growth**, lalu mengevaluasinya dengan **support**, **confidence**, dan **lift**.

1. Import Dataset

	InvoiceNo	StockCode	Description	Quantity	InvoiceDate	UnitPrice	CustomerID	Country
0	536365	85123A	WHITE HANGING HEART T-LIGHT HOLDER	6	2010-12-01 08:26:00	2.55	17850.0	United Kingdom
1	536365	71053	WHITE METAL LANTERN	6	2010-12-01 08:26:00	3.39	17850.0	United Kingdom
2	536365	84406B	CREAM CUPID HEARTS COAT HANGER	8	2010-12-01 08:26:00	2.75	17850.0	United Kingdom
3	536365	84029G	KNITTED UNION FLAG HOT WATER BOTTLE	6	2010-12-01 08:26:00	3.39	17850.0	United Kingdom
4	536365	84029E	RED WOOLLY HOTTIE WHITE HEART.	6	2010-12-01 08:26:00	3.39	17850.0	United Kingdom

```
(541909, 8)
```

```
<class 'pandas.DataFrame'>
RangeIndex: 541909 entries, 0 to 541908
Data columns (total 8 columns):
 #   Column       Non-Null Count   Dtype
---  ------       --------------   -----
 0   InvoiceNo    541909 non-null  object
 1   StockCode    541909 non-null  object
 2   Description  540455 non-null  object
 3   Quantity     541909 non-null  int64
 4   InvoiceDate  541909 non-null  datetime64[us]
 5   UnitPrice    541909 non-null  float64
 6   CustomerID   406829 non-null  float64
 7   Country      541909 non-null  str
dtypes: datetime64[us](1), float64(2), int64(1), object(3), str(1)
memory usage: 33.1+ MB
```

2. Eksplorasi dan Pembersihan Data

Kolom yang relevan untuk association rule: **`InvoiceNo`** (identitas transaksi/keranjang) dan **`Description`** (nama produk/item). `Quantity` dipakai untuk menyaring baris tidak valid.

```
Missing value per kolom:
InvoiceNo           0
StockCode           0
Description      1454
Quantity            0
InvoiceDate         0
UnitPrice           0
CustomerID     135080
Country             0
dtype: int64

Invoice dibatalkan (diawali 'C'): 9288 baris
Quantity <= 0: 10624 baris
```

	baris	invoice unik	produk unik
Data awal	541909	25900	4223
Hapus Description kosong	540455	24446	4223
Hapus invoice dibatalkan ('C')	531167	20610	4207
Hapus Quantity <= 0	530693	20136	4077
Rapikan spasi Description	530693	20136	4065

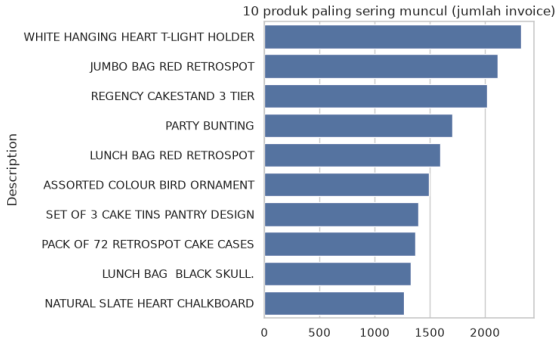
Beberapa baris `Description` bukan produk melainkan biaya/layanan (mis. `POSTAGE`, `Manual`, `AMAZON FEE`). Item seperti ini tidak informatif untuk pola belanja produk, sehingga dibuang sebagai langkah tambahan.

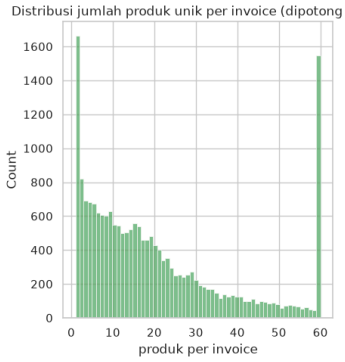
```
Baris non-produk yang dibuang: 2325
Description
POSTAGE                         1126
DOTCOM POSTAGE                   708
Manual                           327
CARRIAGE                         141
Bank Charges                      12
PADS TO MATCH ALL CUSHIONS         4
Adjust bad debt                    3
AMAZON FEE                         2
SAMPLES                            2
Name: count, dtype: int64
```

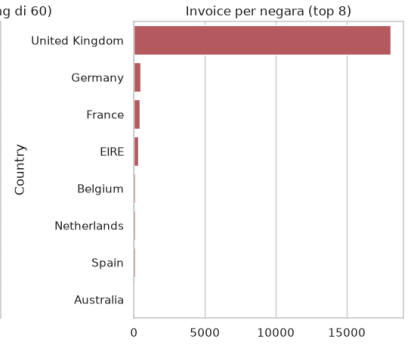
	baris	invoice unik	produk unik
Data awal	541909	25900	4223
Hapus Description kosong	540455	24446	4223
Hapus invoice dibatalkan ('C')	531167	20610	4207
Hapus Quantity <= 0	530693	20136	4077
Rapikan spasi Description	530693	20136	4065
Hapus item non-produk (postage, fee, dll)	528368	19955	4057

```
Sebelum: 541,909 baris, 25,900 invoice
Sesudah: 528,368 baris, 19,955 invoice
```

Eksplorasi singkat data bersih








```
count    19955.000000
mean        25.937058
std         46.829932
min          1.000000
25%          6.000000
50%         15.000000
75%         29.000000
max       1107.000000
Name: Description, dtype: float64
```

3. Persiapan Data untuk Association Rule

Setiap **invoice = satu transaksi**, berisi daftar produk unik yang dibeli. Data diubah ke bentuk one-hot (basket): baris = invoice, kolom = produk, nilai `True` bila produk ada di invoice tersebut (kuantitas tidak dipakai, hanya ada/tidaknya).

```
Contoh 3 transaksi:
536365 -> ['CREAM CUPID HEARTS COAT HANGER', 'GLASS STAR FROSTED T-LIGHT HOLDER', 'KN
ITTED UNION FLAG HOT WATER BOTTLE', 'RED WOOLLY HOTTIE WHITE HEART.', 'SET 7 BABUSHKA
NESTING BOXES'] ...
536366 -> ['HAND WARMER RED POLKA DOT', 'HAND WARMER UNION JACK'] ...
536367 -> ['ASSORTED COLOUR BIRD ORNAMENT', 'BOX OF 6 ASSORTED COLOUR TEASPOONS', 'BO
X OF VINTAGE ALPHABET BLOCKS', 'BOX OF VINTAGE JIGSAW BLOCKS', 'DOORMAT NEW ENGLAND']
...
Jumlah transaksi: 19955

Ukuran basket (invoice x produk): (19955, 4057)
Kepadatan matriks: 0.6393%
```

Description	*Boombox Ipod Classic	*USB Office Mirror Ball	10 COLOUR SPACEBOY PEN	12 COLOURED PARTY BALLOONS	12 DAISY PEGS IN WOOD BOX
InvoiceNo					
536365	False	False	False	False	False
536366	False	False	False	False	False
536367	False	False	False	False	False
536368	False	False	False	False	False
536369	False	False	False	False	False

4. Penerapan Algoritma FP-Growth

Dipilih **FP-Growth** karena lebih efisien daripada Apriori pada matriks yang lebar (ribuan produk) — hasil frequent itemset identik. Parameter awal: `min_support = 0.01`, `min_confidence = 0.5`.

```
Frequent itemset: 1820
panjang
1    808
2    786
3    209
4     16
5      1
Name: count, dtype: int64
```

	support	itemsets	panjang
0	0.113255	frozenset({WHITE HANGING HEART T-LIGHT HOLDER})	1
92	0.104836	frozenset({JUMBO BAG RED RETROSPOT})	1
300	0.099674	frozenset({REGENCY CAKESTAND 3 TIER})	1
590	0.084490	frozenset({PARTY BUNTING})	1
41	0.078376	frozenset({LUNCH BAG RED RETROSPOT})	1
7	0.072914	frozenset({ASSORTED COLOUR BIRD ORNAMENT})	1
621	0.069406	frozenset({SET OF 3 CAKE TINS PANTRY DESIGN})	1
42	0.066149	frozenset({PACK OF 72 RETROSPOT CAKE CASES})	1
174	0.063794	frozenset({LUNCH BAG BLACK SKULL.})	1
79	0.062591	frozenset({NATURAL SLATE HEART CHALKBOARD})	1

```
Jumlah aturan (support>=0.01, confidence>=0.5): 816
```

	support	confidence	lift
count	816.000000	816.000000	816.000000
mean	0.013573	0.652261	18.076972
std	0.004444	0.111833	14.880117
min	0.010023	0.500000	4.776067
25%	0.010724	0.558278	9.425093
50%	0.012127	0.627471	12.601782
75%	0.014595	0.736369	19.127986
max	0.041343	0.953052	79.498872

Sensitivitas parameter

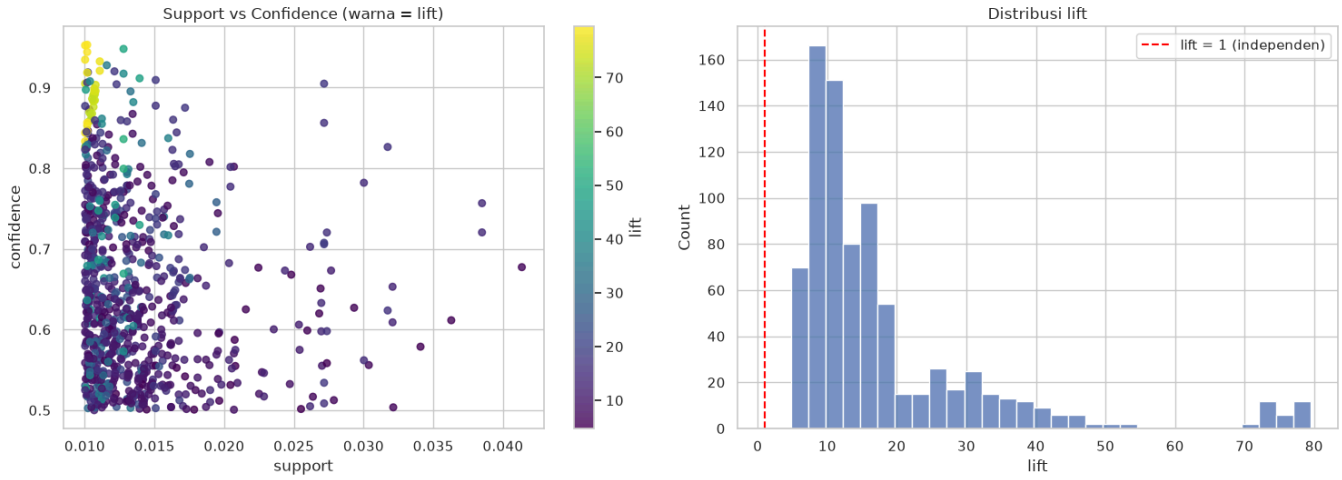
Aturan hasil parameter awal diuji terhadap beberapa kombinasi lain untuk memastikan jumlahnya wajar (tidak terlalu sedikit/banyak).

min_confidence	0.5	0.6	0.7
min_support			
0.005	19585	13436	8157
0.010	816	484	261
0.020	60	30	13
0.030	13	9	4

Dengan `min_support = 0.01` dan `min_confidence = 0.5` dihasilkan ratusan aturan — cukup banyak untuk dianalisis namun masih terbaca. Menaikkan support ke 0.02 memangkas aturan drastis (hanya produk sangat populer yang tersisa), sedangkan menurunkannya ke 0.005 melipatgandakan aturan dan memperlambat komputasi tanpa pola baru yang mencolok. **Parameter awal dipertahankan.**

5. Evaluasi Aturan Asosiasi

	antecedents	consequents	support	confidence	lift
0	HERB MARKER PARSLEY, HERB MARKER ROSEMARY	HERB MARKER THYME	0.010173	0.944186	79.498872
1	HERB MARKER THYME	HERB MARKER PARSLEY, HERB MARKER ROSEMARY	0.010173	0.856540	79.498872
2	HERB MARKER PARSLEY, HERB MARKER THYME	HERB MARKER ROSEMARY	0.010173	0.953052	79.242273
3	HERB MARKER ROSEMARY	HERB MARKER PARSLEY, HERB MARKER THYME	0.010173	0.845833	79.242273
4	HERB MARKER BASIL, HERB MARKER THYME	HERB MARKER ROSEMARY	0.010023	0.952381	79.186508
5	HERB MARKER ROSEMARY	HERB MARKER BASIL, HERB MARKER THYME	0.010023	0.833333	79.186508
6	HERB MARKER THYME	HERB MARKER BASIL, HERB MARKER ROSEMARY	0.010023	0.843882	78.690011
7	HERB MARKER BASIL, HERB MARKER ROSEMARY	HERB MARKER THYME	0.010023	0.934579	78.690011
8	HERB MARKER ROSEMARY	HERB MARKER THYME	0.011075	0.920833	77.532613
9	HERB MARKER THYME	HERB MARKER ROSEMARY	0.011075	0.932489	77.532613
10	HERB MARKER ROSEMARY, HERB MARKER THYME	HERB MARKER PARSLEY	0.010173	0.918552	77.015571
11	HERB MARKER PARSLEY	HERB MARKER ROSEMARY, HERB MARKER THYME	0.010173	0.852941	77.015571
12	HERB MARKER PARSLEY	HERB MARKER THYME	0.010674	0.894958	75.353952
13	HERB MARKER THYME	HERB MARKER PARSLEY	0.010674	0.898734	75.353952
14	HERB MARKER PARSLEY	HERB MARKER ROSEMARY	0.010774	0.903361	75.110732

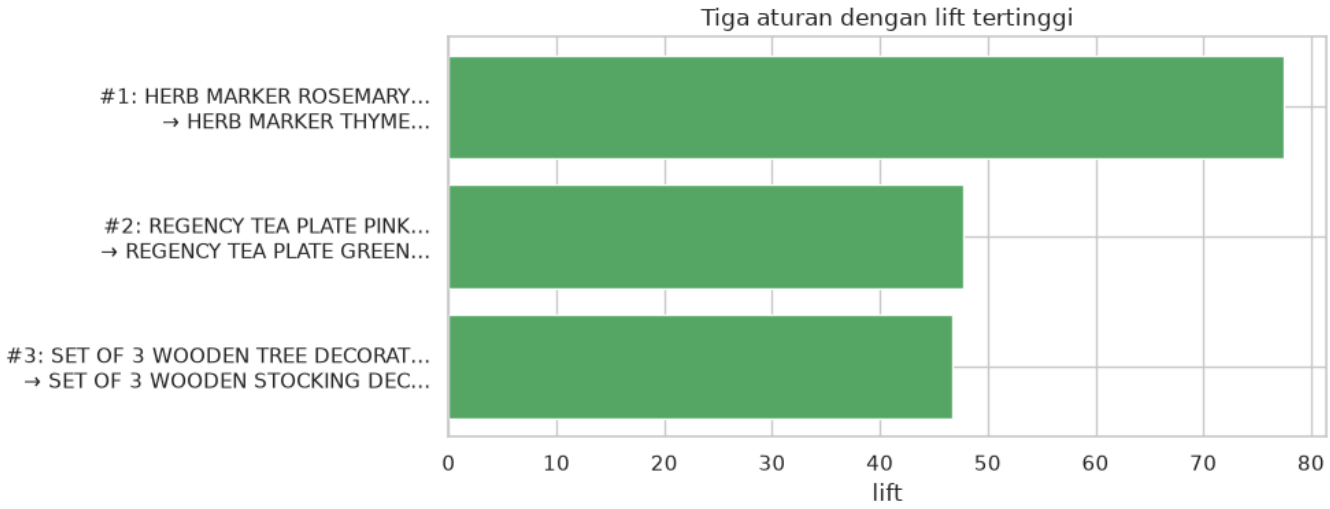


Tiga aturan terbaik berdasarkan lift

Peringkat lift mentah didominasi satu keluarga produk (*herb marker*: Thyme, Rosemary, Parsley, Mint, Basil) yang muncul puluhan kali dalam kombinasi berbeda, dan setiap aturan `A → B` punya kembaran `B → A` dengan lift sama. Agar tiga aturan yang dipilih informatif dan tidak redundan, dipakai tiga langkah:

1. hanya aturan satu item → satu item (mudah diinterpretasi),
2. satu arah per pasangan (lift tertinggi, lalu confidence tertinggi),
3. tiap aturan terpilih berasal dari keluarga produk berbeda (kata pertama nama produk berbeda).

	antecedents	consequents	support	confidence	lift
1	HERB MARKER ROSEMARY	HERB MARKER THYME	0.011075	0.920833	77.532613
2	REGENCY TEA PLATE PINK	REGENCY TEA PLATE GREEN	0.013931	0.911475	47.738824
3	SET OF 3 WOODEN TREE DECORATIONS	SET OF 3 WOODEN STOCKING DECORATION	0.010975	0.747440	46.756021



Interpretasi bisnis

Semua aturan memiliki lift jauh di atas 1 (minimum 4,78; median 12,6), artinya produk-produk tersebut dibeli bersamaan jauh lebih sering daripada kebetulan.

#	Aturan	Support	Confidence	Lift
1	HERB MARKER ROSEMARY → HERB MARKER THYME	1,11% (≈221 invoice)	92,1%	77,5
2	REGENCY TEA PLATE PINK → REGENCY TEA PLATE GREEN	1,39% (≈278 invoice)	91,1%	47,7
3	SET OF 3 WOODEN TREE DECORATIONS → SET OF 3 WOODEN STOCKING DECORATION	1,10% (≈219 invoice)	74,7%	46,8

1. **Herb marker Rosemary → Thyme.** Dari setiap 100 invoice berisi penanda tanaman Rosemary, sekitar 92 juga berisi Thyme, dan peluangnya 77 kali lebih tinggi daripada pembelian acak. Pelanggan membeli *seluruh set* herb marker (Basil, Mint, Parsley, Rosemary, Thyme), bukan satuan. Implikasi: jual sebagai bundle/paket lengkap dan tampilkan semua varian berdampingan.
2. **Regency tea plate Pink → Green.** Pelanggan melengkapi koleksi warna dalam satu seri produk (lini Regency juga berasosiasi dengan teapot, sugar bowl, milk jug). Implikasi: rekomendasi "lengkapi koleksi" di halaman produk dan penawaran set tea party.
3. **Wooden tree decorations → wooden stocking decorations.** Pola musiman Natal: pembeli dekorasi pohon juga mengambil dekorasi lain dari seri sama (sekitar 75%). Implikasi: tata letak/bundle bertema Natal dan stok dikoordinasikan antarproduk seri tersebut menjelang musim.

Catatan: support tiap aturan hanya ≈1%, jadi pola ini berlaku pada segmen pembeli tertentu (kemungkinan besar pelanggan grosir/reseller yang membeli seri produk lengkap), bukan seluruh transaksi. Lift sangat tinggi pada itemset ber-support kecil juga bisa membesar karena produk komponennya sendiri jarang.

6. Kesimpulan

- **Data:** dari 541.909 baris / 25.900 invoice, pembersihan (Description kosong, invoice batal "C", Quantity ≤ 0, dan item non-produk seperti POSTAGE) menyisakan **528.368 baris, 19.955 invoice, 4.057 produk unik**. Matriks basket sangat jarang (kepadatan ≈0,64%), rata-rata ≈26 produk unik per invoice (median 15).
- **Algoritma:** FP-Growth dengan `min_support = 0,01` dan `min_confidence = 0,5` menghasilkan **1.820 frequent itemset** dan **816 aturan** — jumlah yang wajar, sehingga parameter tidak diubah. Menaikkan support ke 0,02 menyisakan hanya 60 aturan; menurunkannya ke 0,005 menghasilkan ≈19.600 aturan.
- **Pola dominan:** aturan dengan lift tertinggi berasal dari **produk satu seri/varian** (herb marker, Regency tea set, dekorasi kayu Natal, polkadot cup/bowl, jam jar warna). Pelanggan cenderung membeli produk pelengkap dalam satu lini, bukan lintas kategori.
- **Implikasi bisnis:** bundling set lengkap, rekomendasi "lengkapi koleksi", penataan produk seri berdampingan, dan perencanaan stok bersama untuk produk satu seri (terutama musiman).
- **Keterbatasan:** support rendah (≈1–4%) dan basis pelanggan campuran (ritel + grosir) berarti aturan berlaku pada segmen tertentu; lift yang sangat tinggi perlu dibaca bersama support agar tidak berlebihan menafsirkan.