Laporan Tugas Association Rule

Analisis Keranjang Belanja pada Dataset Online Retail

Muhammad Irzam Hafis Fabiansyah — 5054251024

1. Pendahuluan

Tugas ini menerapkan *association rule mining* pada dataset **Online Retail** (UCI Machine Learning Repository): transaksi ritel online di Inggris, Desember 2010 – Desember 2011 (541.909 baris, 8 kolom). Tujuannya menemukan produk yang sering dibeli bersamaan menggunakan algoritma **FP-Growth** dan mengevaluasinya dengan metrik *support*, *confidence*, dan *lift*.

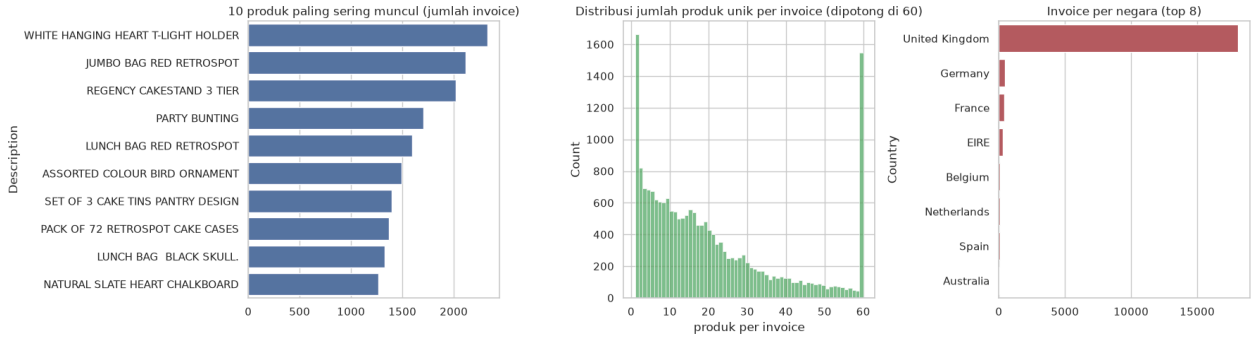
2. Eksplorasi dan Pembersihan Data

Kolom yang relevan adalah `InvoiceNo` (identitas transaksi) dan `Description` (nama produk). Pembersihan dilakukan bertahap:

No	Langkah	Baris	Invoice	Produk unik
0	Data awal	541.909	25.900	4.223
1	Hapus `Description` kosong	540.455	24.446	4.223
2	Hapus invoice dibatalkan (awalan “C”)	531.167	20.610	4.207
3	Hapus `Quantity` ≤ 0	530.693	20.136	4.077
4	Rapikan spasi pada `Description`	530.693	20.136	4.065
5	Hapus item non-produk (POSTAGE, Manual, fee, dll.)	528.368	19.955	4.057

Tabel 1: Jumlah baris dan invoice pada setiap tahap pembersihan.

Langkah 5 adalah tambahan: item seperti `POSTAGE`, `DOTCOM POSTAGE`, dan `Manual` merupakan biaya/layanan, bukan produk, sehingga tidak informatif untuk pola belanja. Hasil akhirnya **528.368 baris dan 19.955 invoice**.



Gambar 1: Produk terpopuler, distribusi jumlah produk per invoice, dan invoice per negara.

Rata-rata sebuah invoice berisi sekitar 26 produk unik (median 15, maksimum 1.107), dan sebagian besar transaksi berasal dari Inggris.

3. Persiapan Data

Setiap invoice dijadikan satu transaksi berisi himpunan produk unik, lalu diubah ke bentuk one-hot (baris = invoice, kolom = produk). Matriks yang terbentuk berukuran **19.955 × 4.057** dengan kepadatan hanya 0,64% — sangat jarang, sehingga FP-Growth dipilih karena lebih efisien daripada Apriori dan menghasilkan itemset yang sama.

4. Penerapan Algoritma

Dengan `min_support = 0,01` dan `min_confidence = 0,5` diperoleh **1.820 frequent itemset** (808 satu item, 786 dua item, 209 tiga item, 16 empat item, 1 lima item) dan **816 aturan**. Jumlah ini dianggap wajar untuk dianalisis, sehingga parameter awal tidak diubah. Pengujian sensitivitas menunjukkan alasannya:

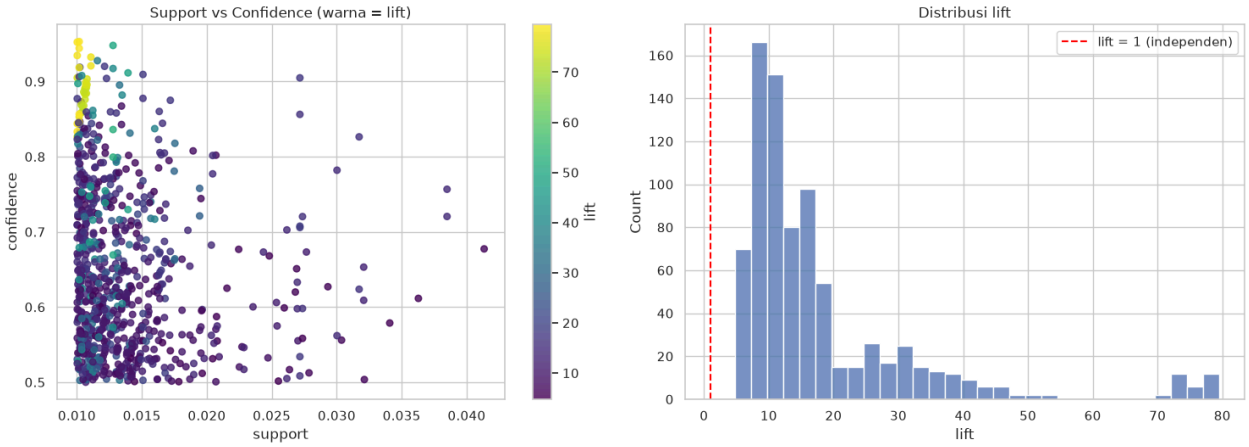
min_support \ min_confidence	0,5	0,6	0,7
0,005	19.585	13.436	8.157
0,010	**816**	484	261
0,020	60	30	13
0,030	13	9	4

Tabel 2: Jumlah aturan untuk berbagai kombinasi parameter.

Support 0,005 menghasilkan hampir 20 ribu aturan yang tak mungkin ditelaah, sedangkan support ≥ 0,02 menyisakan terlalu sedikit aturan dan hanya produk sangat populer.

5. Evaluasi Aturan

Seluruh 816 aturan memiliki lift antara 4,78 dan 79,5 (median 12,6), confidence rata-rata 65%, dan support 1,0%–4,1%. Semua lift jauh di atas 1, sehingga pasangan produk tersebut dibeli bersamaan jauh lebih sering daripada kebetulan.



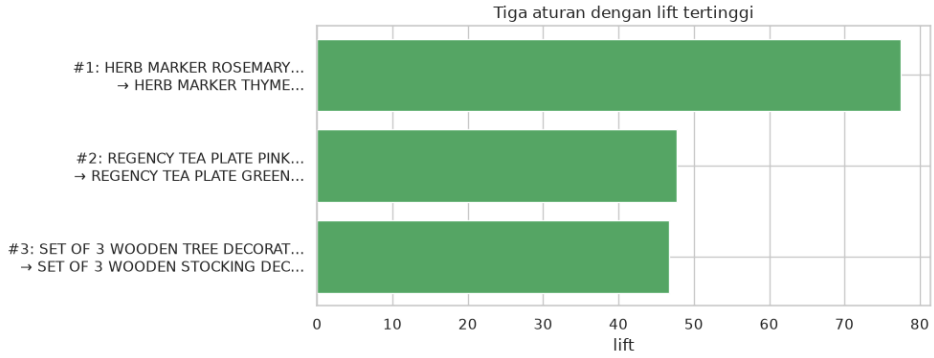
Gambar 2: Kiri: support vs confidence (warna = lift). Kanan: distribusi lift.

5.1. Tiga aturan terbaik berdasarkan lift

Peringkat lift mentah didominasi satu keluarga produk (*herb marker*), dan tiap aturan memiliki kembaran arah sebaliknya dengan lift yang sama. Agar tiga aturan terpilih tidak redundan, dipakai aturan satu item ⟶ satu item, satu arah per pasangan, dan tiap aturan dari keluarga produk berbeda.

#	Aturan	Support	Confidence	Lift
1	Herb Marker Rosemary ⟶ Herb Marker Thyme	1,11%	92,1%	77,5
2	Regency Tea Plate Pink ⟶ Regency Tea Plate Green	1,39%	91,1%	47,7
3	Set of 3 Wooden Tree Decorations ⟶ Set of 3 Wooden Stocking Decoration	1,10%	74,7%	46,8

Tabel 3: Tiga aturan dengan lift tertinggi.



Gambar 3: Lift tiga aturan terbaik.

Interpretasi bisnis

1. **Herb marker Rosemary → Thyme.** Dari 100 invoice berisi Rosemary, sekitar 92 juga berisi Thyme, dengan peluang 77 kali lebih tinggi daripada acak. Pelanggan membeli satu set penanda tanaman lengkap (Basil, Mint, Parsley, Rosemary, Thyme). Saran: jual sebagai paket dan tampilkan semua varian berdampingan.
2. **Regency tea plate Pink → Green.** Pelanggan melengkapi koleksi warna dalam satu seri; lini Regency juga berasosiasi dengan teapot, sugar bowl, dan milk jug. Saran: rekomendasi "lengkapi koleksi" dan paket tea party.
3. **Wooden tree decorations → stocking decorations.** Pola musiman Natal: pembeli dekorasi pohon mengambil dekorasi lain seri yang sama (≈75%). Saran: bundel bertema Natal dan stok yang dikoordinasikan antarproduk seri tersebut.

6. Kesimpulan

- Pembersihan menyisakan 19.955 invoice dan 4.057 produk dari data awal 25.900 invoice; matriks transaksi sangat jarang (0,64%).
- FP-Growth dengan support 0,01 dan confidence 0,5 menghasilkan 816 aturan yang semuanya berlift > 1 (4,78–79,5).
- Pola dominan adalah pembelian **produk pelengkap dalam satu seri/varian** (herb marker, Regency tea set, dekorasi kayu Natal, polkadot cup/bowl), bukan lintas kategori.
- Implikasi: bundling set lengkap, rekomendasi "lengkapi koleksi", penataan produk satu seri berdampingan, dan perencanaan stok bersama, terutama untuk produk musiman.
- Keterbatasan: support tiap aturan hanya sekitar 1–4%, sehingga pola berlaku pada segmen tertentu (kemungkinan pembeli grosir/reseller). Lift yang sangat tinggi perlu dibaca bersama support agar tidak ditafsirkan berlebihan.