Laporan Tugas Sequential Pattern Analysis

Pola Pembelian Berurutan pada Dataset Online Retail

Muhammad Irzam Hafis Fabiansyah — 5054251024

1. Pendahuluan

Tugas ini mencari pola urutan barang yang dibeli pelanggan (*sequential pattern mining*) pada dataset **Online Retail** dari UCI: transaksi toko online di Inggris, Desember 2010 sampai Desember 2011 (541.909 baris, 8 kolom). Tiap pelanggan dijadikan satu urutan pembelian menurut waktu, lalu pola yang sering muncul dicari dengan algoritma **PrefixSpan** dan dinilai dengan *support* dan *confidence*.

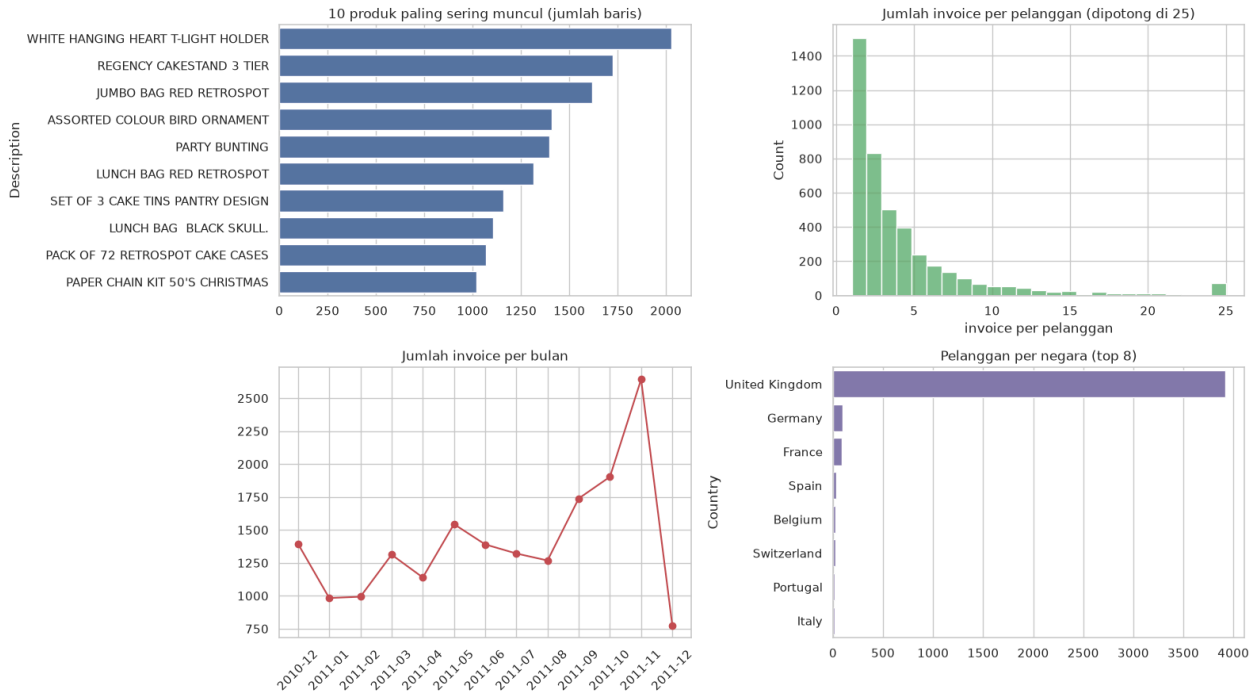
2. Eksplorasi dan Pembersihan Data

Kolom yang dipakai: `CustomerID` (siapa pembelinya), `InvoiceDate` (kapan beli), `InvoiceNo` (satu transaksi), dan `Description` (nama barang).

No	Langkah	Baris	Invoice	Pelanggan	Produk
0	Data awal	541.909	25.900	4.372	4.223
1	Hapus `Description` kosong	540.455	24.446	4.372	4.223
2	Hapus invoice dibatalkan (“C”)	531.167	20.610	4.339	4.207
3	Hapus `Quantity` ≤ 0	530.693	20.136	4.339	4.077
4	Hapus `CustomerID` kosong	397.924	18.536	4.339	3.877
5	Rapikan spasi `Description`	397.924	18.536	4.339	3.866
6	Hapus item non-produk (POSTAGE, Manual, dll.)	396.370	18.405	4.335	3.860

Tabel 1: Jumlah baris, invoice, pelanggan, dan produk unik pada setiap tahap pembersihan.

Yang paling banyak dibuang adalah baris tanpa `CustomerID` (sekitar 133 ribu baris), karena urutan pembelian disusun per pelanggan. Langkah 6 tambahan dari saya: `POSTAGE`, `Manual`, `CARRIAGE`, dan sejenisnya adalah biaya, bukan barang. Hasil akhirnya **396.370 baris, 18.405 invoice, dan 4.335 pelanggan**.



Gambar 1: Produk terpopuler, invoice per pelanggan, invoice per bulan, dan pelanggan per negara.

Rata-rata pelanggan punya 4,2 invoice (median 2, paling banyak 206). Sebanyak **2.829 pelanggan (65%)** punya minimal dua invoice, jadi urutan belinya benar-benar terbentuk. Jumlah invoice paling ramai menjelang akhir tahun.

3. Persiapan Data

Data diurutkan per `CustomerID` dan `InvoiceDate`. Barang dalam satu invoice dijadikan satu itemset (barang yang sama dalam satu invoice dihitung sekali), dan tiap pelanggan jadi satu sequence berupa daftar itemset menurut waktu (*list of list*). Hasilnya **4.335 sequence**.

Library `prefixspan` hanya menerima daftar barang, bukan daftar itemset, jadi itemset digabung berurutan menurut invoice. Panjang sequence rata-rata 89 barang (median 40). Akibatnya, barang dalam satu invoice ikut berurutan sesuai baris di data, jadi sebagian pola antar barang bisa berasal dari satu invoice yang sama. Pola yang mengulang barang yang sama (`X → X`) pasti terjadi di dua invoice atau lebih.

4. Penerapan Algoritma

Saya mulai dari `min_support = 0,01` (sekitar 44 pelanggan), tapi ternyata terlalu kecil: polanya terlalu banyak dan perhitungannya tidak selesai dalam waktu wajar. Ini perbandingan beberapa nilai support:

min_support	Batas panjang	Min. pelanggan	Jumlah pola	Waktu (dtk)
0,01	≤ 2	44	27.125	11,0
0,05	tanpa batas	217	305	4,0
0,03	tanpa batas	131	1.328	13,2
0,02	tanpa batas	**87**	**5.991**	44,8

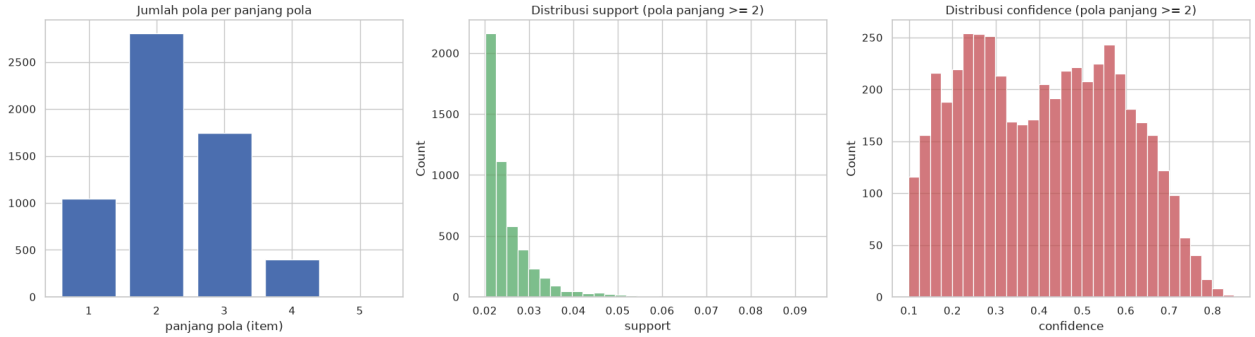
Tabel 2: Jumlah pola untuk berbagai nilai minimum support.

Dengan support 0,01, pola sepanjang ≤ 2 saja sudah puluhan ribu. Dengan 0,05, polanya tinggal 305 dan kebanyakan barang paling populer. Jadi dipilih **`min_support = 0,02`** (minimal 87 pelanggan): polanya ribuan tapi masih bisa dibaca, dan perhitungannya cukup cepat.

5. Evaluasi Pola Berurutan

Support adalah persen pelanggan yang urutan belinya mengandung pola itu. Confidence pola $\langle a_1, \ldots, a_k \rangle$ adalah support($a_1 \ldots a_k$) / support($a_1 \ldots a_{k-1}$), yaitu dari pelanggan yang sudah membeli bagian awal pola, berapa persen yang kemudian membeli barang terakhirnya.

Ada **5.991 pola**: 1.044 pola satu barang dan **4.947 pola berurutan** (2.805 pola dua barang, 1.744 tiga barang, 397 empat barang, dan 1 pola lima barang). Pola berurutan punya support 2,0%–9,3% (rata-rata 2,5%) dan confidence rata-rata 41% (paling tinggi 84,9%).



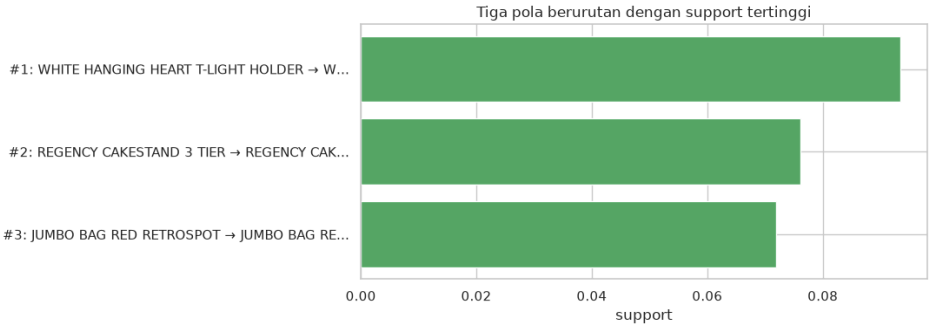
Gambar 2: Jumlah pola per panjang, distribusi support, dan distribusi confidence (pola panjang ≥ 2).

5.1. Tiga pola terbaik berdasarkan support

Pola satu barang cuma menunjukkan barang itu populer, jadi tiga pola terbaik diambil dari pola berurutan (minimal dua barang) dengan support tertinggi. Support ketiganya sudah dicek dengan hitungan langsung (tanpa PrefixSpan) dan hasilnya sama.

#	Pola berurutan	Pelanggan	Support	Confidence
1	White Hanging Heart T-Light Holder ⟶ White Hanging Heart T-Light Holder	405	9,34%	47,3%
2	Regency Cakestand 3 Tier ⟶ Regency Cakestand 3 Tier	330	7,61%	37,5%
3	Jumbo Bag Red Retrospot ⟶ Jumbo Bag Red Retrospot	312	7,20%	49,1%

Tabel 3: Tiga pola berurutan dengan support tertinggi.



Gambar 3: Support tiga pola terbaik.

Artinya buat bisnis. Ketiganya sama-sama beli barang yang sama lagi di invoice yang berbeda.

1. **White Hanging Heart T-Light Holder.** 405 pelanggan (9,3%) membelinya dua kali atau lebih. Dari 856 pelanggan yang pernah membelinya, 47,3% beli lagi. Barang ini juga yang paling populer secara keseluruhan, jadi ia best seller yang sering dibeli ulang.
2. **Regency Cakestand 3 Tier.** Support 7,6%, confidence 37,5%. Pembeli yang kembali mungkin menambah stok untuk dijual lagi atau melengkapi set. Seri Regency juga sering dibeli berurutan dengan barang lain (cakestand lalu Roses Regency Teacup and Saucer, support 5,8%).

3. **Jumbo Bag Red Retrospot.** Support 7,2% dengan confidence paling tinggi dari ketiganya (49,1%): hampir separuh pembelinya beli lagi. Mungkin barang ini cepat habis atau dibeli untuk dijual lagi.

Saran: kirim pengingat beli ulang, beri diskon untuk pembelian banyak atau paket langganan, dan utamakan stok barang yang sering dibeli ulang.

6. Kesimpulan

- Setelah dibersihkan, tersisa 396.370 baris, 18.405 invoice, dan 4.335 pelanggan; 65% pelanggan punya minimal 2 invoice.
- PrefixSpan dengan support 0,02 menemukan 5.991 pola (4.947 di antaranya berurutan, 2–5 barang). Support 0,01 tidak dipakai karena polanya terlalu banyak.
- Pola yang paling sering adalah **beli barang yang sama lagi** (support tertinggi 9,3%), lalu urutan antar varian dalam satu seri barang (bunting, lunch bag, paper chain kit).
- Saran bisnis: jaga pelanggan lama dan siapkan stok best seller, plus promo untuk pembelian banyak atau langganan.
- Keterbatasan: support pola kecil (rata-rata 2,5%) karena banyak pelanggan cuma belanja sekali dan datanya hanya setahun; pelanggannya juga campuran eceran dan grosir. Karena `prefixspan` tidak mendukung itemset, pola antar barang bisa berasal dari satu invoice yang sama.