

LAPORAN PRAKTIKUM 1

Scraping Data dan Exploratory Data Analysis

Muhammad Irzam Hafis Fabiansyah (5054251024)

1. Tujuan

Praktikum ini mengambil data gizi produk pangan dari Open Food Facts lewat API resminya, membersihkannya, lalu menganalisisnya dengan EDA.

Pertanyaan yang dijawab: zat gizi apa yang paling menentukan sebuah produk mendapat label Nutri-Score **a** (terbaik) atau **e** (terburuk)?

2. Dasar teori

Open Food Facts adalah basis data produk pangan terbuka yang diisi sukarela oleh kontributor. Tiap produk bisa memiliki info gizi per 100 g dan label **Nutri-Score**, yaitu peringkat gizi lima tingkat dari **a** (paling sehat) sampai **e** (paling tidak sehat).

Nutri-Score dihitung dari skor gabungan: energi, gula, lemak jenuh, dan garam memberi poin penalti, sedangkan serat, protein, serta buah/sayur/kacang memberi poin pengurang. Tiap nutrisi tidak dijumlahkan begitu saja, melainkan dipetakan dulu ke poin diskret lewat tabel ambang.

Label Nutri-Score bersifat **ordinal**, urutannya jelas (**a** < **b** < **c** < **d** < **e**) tapi jaraknya tidak setara, jadi korelasi yang tepat adalah **Spearman**, yaitu korelasi Pearson yang dihitung atas peringkat data, bukan atas nilai aslinya:

$$\rho = 1 - \frac{6 \sum d_i^2}{n(n^2 - 1)}$$

dengan d_i selisih peringkat pasangan data ke- i dan n banyaknya data. Selain cocok untuk data ordinal, Spearman juga tahan terhadap sebaran miring dan outlier, dua hal yang memang terlihat di data gizi ini.

3. Alat dan bahan

Komponen	Keterangan
Bahasa	Python 3.13
Library	<code>requests</code> , <code>pandas</code> , <code>numpy</code> , <code>matplotlib</code>
Environment	Jupyter Notebook
Sumber data	Open Food Facts API v2 (<code>world.openfoodfacts.org/api/v2/search</code>)
Berkas kerja	<code>5054251024_..._Tugas_Scrapping.ipynb</code> , <code>5054251024_..._Tugas_EDA.ipynb</code> , <code>data/off_nutrition.csv</code>

4. Langkah kerja

4.1. Scraping (5054251024_..._Tugas_Scrapping.ipynb)

Data diambil dari endpoint `search` dengan filter `nutrition_grades_tags` untuk tiap grade `a` – `e`. Tiap grade diambil 4 halaman berisi 100 produk, jadi target sampelnya $5 \times 4 \times 100 = 2000$ produk yang **berimbang per label**.

Kolom yang diminta ada dua kelompok: metadata (`code`, `product_name`, `brands`, `nutriscore_grade`, `nutriscore_score`, `nova_group`) dan sembilan kolom gizi per 100 g (energi, lemak, lemak jenuh, karbohidrat, gula, serat, protein, garam, dan estimasi buah/sayur/kacang).

Tiga hal teknis yang dipasang di tahap ini:

1. **retry berjenjang:** server Open Food Facts sering membalas HTTP 503 (sibuk), jadi permintaan diulang sampai 8 kali dengan jeda yang membesar (`delay × percobaan`). Error permanen di luar 429/5xx langsung dilempar, tidak perlu diulang.
2. **cache berkas:** respons tiap halaman disimpan sebagai JSON di `data/raw/`, hasil akhirnya jadi `data/off_nutrition.csv`. Menjalankan ulang notebook karena itu tidak memicu permintaan jaringan lagi, hasilnya bisa direproduksi, dan servernya tidak dibebani berulang kali.
3. **jeda antarpermintaan:** `time.sleep(delay)` di antara halaman untuk menghindari rate-limit.

Respons API menaruh semua angka gizi di dalam nested object `nutriments`, jadi tiap produk harus di-flatten terlebih dahulu menjadi satu baris datar sebelum dikumpulkan jadi `DataFrame`.

4.2. Pembersihan data (5054251024_..._Tugas_EDA.ipynb)

Open Food Facts diisi sukarela oleh kontributor, jadi wajar ada nilai kosong, duplikat, dan angka mustahil (misalnya lemak 900 g per 100 g). Langkah pembersihannya:

1. **duplikat:** satu produk (`code`) bisa muncul di lebih dari satu halaman
2. **tipe data:** semua kolom gizi dipaksa numerik, teks yang gagal jadi `NaN`
3. **rentang wajar:** massa per 100 g tidak mungkin negatif atau melebihi 100 g, dan energi dibatasi 900 kkal (lemak murni ≈ 900 kkal/100 g). Nilai di luar itu kemungkinan besar salah input, bukan outlier asli, jadi dijadikan `NaN` karena kolom lain di baris yang sama masih berguna
4. **label:** `nutriscore_grade` dijadikan `Categorical` terurut, lalu diturunkan jadi `grade_ordinal` bernilai 1–5 (`a`=1 s.d. `e`=5, makin besar makin buruk) supaya bisa dikorelasikan

5. Hasil dan pembahasan

5.1. Gambaran umum dataset

Hasil scraping berukuran **1999 baris × 15 kolom**: kurang satu dari target 2000 karena grade `e` hanya mengembalikan 399 produk unik. Setelah dibersihkan jumlah barisnya tetap 1999, artinya tidak ada duplikat `code` maupun label kosong, hanya bertambah kolom

`grade_ordinal`. Sebaran labelnya praktis berimbang: 400 produk untuk `a–d` dan 399 untuk `e`.

Kolom	Kosong	%
<code>fiber_100g</code>	534	26.7
<code>fruits-veg-nuts..._100g</code>	242	12.1
<code>nova_group</code>	137	6.9
<code>carbohydrates_100g</code>	109	5.5
<code>saturated-fat_100g</code>	104	5.2
<code>sugars_100g</code>	103	5.2
<code>fat_100g</code>	102	5.1
<code>proteins_100g</code>	101	5.1
<code>energy-kcal_100g</code>	100	5.0
<code>salt_100g</code>	83	4.2
<code>product_name</code>	36	1.8
<code>brands</code>	36	1.8

Tabel 1: Nilai hilang tiap atribut. `code`, `nutriscore_grade`, dan `nutriscore_score` terisi penuh, jadi tidak ditampilkan.

Delapan dari sembilan kolom gizi kosong di bawah 13%, tapi `fiber_100g` bolong 26.7% — paling jarang diisi kontributor.

Penanganannya: baris tidak dibuang. Tiap korelasi dihitung dengan pasangan data yang tersedia saja (`pandas` mengabaikan `NaN` sendiri), jadi baris yang kosong di satu kolom masih menyumbang lewat kolom lain. Kolom `n` di Tabel 5 mencatat berapa data yang benar-benar dipakai. Satu-satunya yang wajib ada adalah `nutriscore_grade` karena itu variabel targetnya, dan barisnya sudah di-`dropna` saat pembersihan.

5.2. Tipe atribut

Tipe data `pandas` belum tentu sama dengan tipe atribut secara statistik. `nova_group` misalnya terbaca `float64` padahal isinya peringkat 1–4 yang tidak boleh dirata-rata. Karena itu tiap kolom dilabeli manual:

Tipe	Kolom
Nominal	<code>code</code> , <code>product_name</code> , <code>brands</code>
Ordinal	<code>nutriscore_grade</code> (<code>a–e</code>), <code>nova_group</code> (1–4)
Numerik diskret	<code>nutriscore_score</code> (skor gabungan, bilangan bulat)
Numerik kontinu	sembilan kolom gizi per 100 g

Tabel 2: Tipe tiap atribut dalam dataset.

5.3. Statistik deskriptif

Kolom	n	mean	std	modus	Q1	median	Q3	maks
energy-kcal_100g	1899	300.26	209.49	0.0	98.51	289.00	456.00	900.0
fat_100g	1897	16.22	20.21	0.0	1.90	8.30	23.00	100.0
saturated-fat_100g	1895	5.45	8.38	0.0	0.40	1.70	7.20	60.0
carbohydrates_100g	1890	29.96	27.69	0.0	4.50	18.18	57.50	100.0
sugars_100g	1896	11.44	16.28	0.0	1.10	4.40	15.00	100.0
fiber_100g	1465	4.18	4.69	0.0	0.50	3.00	6.50	66.0
proteins_100g	1898	7.42	6.62	0.0	2.70	6.70	9.80	75.0
salt_100g	1916	0.66	1.61	0.0	0.03	0.30	0.95	44.6
fruits-veg-nuts..._100g	1757	13.73	26.22	0.0	0.00	0.00	13.00	100.0

Tabel 3: Statistik deskriptif kolom gizi (g per 100 g, kecuali energi dalam kkal).

Perhatikan jarak antara median dan rata-rata pada kolom seperti `sugars_100g` (mean 11.44 vs median 4.40) dan `salt_100g` (0.66 vs 0.30): kalau rata-rata jauh di atas median, sebarannya miring ke kanan — banyak produk berkadar rendah, sedikit produk berkadar sangat tinggi yang menarik rata-rata ke atas. Ini alasan utama memilih korelasi berbasis peringkat dan ringkasan berbasis median di bagian berikutnya.

Modusnya 0.0 di semua kolom. Ini bukan salah hitung, melainkan gejala yang sama: nilai nol adalah angka paling sering muncul di data gizi produk kemasan (banyak produk bebas serat, bebas lemak, atau tanpa buah/sayur sama sekali), sehingga modus praktis tidak informatif di sini.

5.4. Outlier

Pembersihan tadi hanya membuang nilai yang **mustahil**; yang tersisa masih bisa mengandung nilai ekstrem yang sah. Deteksinya pakai aturan IQR: nilai di luar $Q_1(1.5 \cdot \text{IQR})$ sampai $Q_3 + 1.5 \cdot \text{IQR}$ ditandai outlier. Batas bawahnya selalu negatif karena kandungan gizi tidak pernah kurang dari nol, jadi semua outlier di sini adalah outlier atas.

Kolom gizi	Batas atas	Outlier	%
fruits-veg-nuts..._100g	32.50	251	14.3
sugars_100g	35.85	182	9.6
saturated-fat_100g	17.40	151	8.0
proteins_100g	20.45	125	6.6
fat_100g	54.65	101	5.3
salt_100g	2.32	53	2.8
fiber_100g	15.50	31	2.1
energy-kcal_100g	992.24	0	0.0
carbohydrates_100g	137.00	0	0.0


Tabel 4: Outlier tiap kolom gizi menurut aturan IQR.

Penanganannya: outlier ini dibiarkan, tidak dibuang maupun dipangkas. Nilai seperti lemak 100 g per 100 g (minyak goreng) atau garam 44 g per 100 g (garam meja) memang

produk nyata, yang salah input sudah disaring di tahap pembersihan. Membuangnya justru menghapus produk grade **e** yang paling informatif. Pengaruhnya pada analisis juga sudah diantisipasi: seluruh korelasi memakai Spearman yang bekerja atas peringkat, dan ringkasan per grade memakai median, jadi keduanya tidak tertarik nilai ekstrem. **energy-kcal_100g** dan **carbohydrates_100g** tidak punya outlier karena batas atas IQR-nya (992 kkal dan 137 g) sudah melewati batas fisik yang dipasang saat pembersihan.


5.5. Visualisasi univariat

Sebelum melihat hubungan antar atribut, lihat dulu sebaran tiap atribut sendiri-sendiri: histogram untuk kolom numerik, bar chart untuk kolom kategorikal.



Gambar 1: Sebaran tiap kolom gizi.

Hampir semua kolom menumpuk di dekat nol dengan ekor panjang ke kanan—persis kemiringan yang terbaca dari jarak mean vs median di Tabel 3. **fruits-veg-nuts..._100g** paling ekstrem menumpuk di 0, dan itu menjelaskan kenapa modusnya nol tadi.



Gambar 2: Jumlah produk per label Nutri-Score dan per kelompok NOVA.

Sebaran label sengaja dibuat berimbang karena scraping-nya memfilter per grade, jadi bar chart kiri rata: ini rancangan sampel, bukan temuan. Sebaliknya `nova_group` tidak difilter, dan hasilnya miring ke NOVA 4 sebanyak 1119 produk (ultra-olahan), wajar karena basis data Open Food Facts didominasi produk kemasan.


5.6. Korelasi gizi dengan label

Tanda korelasi dibaca sebagai berikut:

- **positif** → makin tinggi kandungannya, makin buruk labelnya (bergerak ke `e`)
- **negatif** → makin tinggi kandungannya, makin baik labelnya (bergerak ke `a`)

Kolom gizi	Spearman	n	Arah
<code>proteins_100g</code>	-0.139	1898	memperbaiki label
<code>fiber_100g</code>	-0.122	1465	memperbaiki label
<code>fruits-veg-nuts..._100g</code>	-0.047	1757	memperbaiki label
<code>salt_100g</code>	+0.173	1916	memperburuk label
<code>carbohydrates_100g</code>	+0.233	1890	memperburuk label
<code>fat_100g</code>	+0.394	1897	memperburuk label
<code>energy-kcal_100g</code>	+0.397	1899	memperburuk label
<code>saturated-fat_100g</code>	+0.473	1895	memperburuk label
<code>sugars_100g</code>	+0.502	1896	memperburuk label

Tabel 5: Korelasi Spearman zat gizi terhadap `grade_ordinal` (`a` =1 s.d. `e` =5).



Gambar 3: Korelasi Spearman tiap zat gizi terhadap label. Merah memperburuk label, hijau memperbaiki.


Empat penentu terkuat ($|\text{Spearman}|$ terbesar) adalah gula (+0.502), lemak jenuh (+0.473), energi (+0.397), dan lemak total (+0.394). Sebaliknya protein (-0.139) dan serat (-0.122) berkorelasi negatif. Arah ini persis sesuai rumus resmi Nutri-Score di bagian dasar teori.

5.7. Bentuk hubungannya

Korelasi meringkas arah hubungan jadi satu angka. Tabel dan boxplot berikut menunjukkan bentuknya: apakah benar naik monoton dari **a** ke **e**, atau justru mendatar di grade tengah. Median dipakai, bukan rata-rata, karena alasan kemiringan sebaran tadi.

Kolom gizi (median)	a	b	c	d	e
jumlah produk	400	400	400	400	399
energy-kcal_100g	139.0	155.5	283.0	345.0	484.0
fat_100g	2.8	3.2	8.0	19.0	24.0
saturated-fat_100g	0.5	1.0	1.8	4.8	9.0
carbohydrates_100g	8.00	8.17	16.75	24.00	50.86
sugars_100g	2.60	2.30	4.50	6.50	28.65
fiber_100g	4.4	2.8	3.9	3.0	2.5
proteins_100g	9.70	5.40	7.00	6.95	6.00
salt_100g	0.10	0.18	0.49	0.75	0.26
fruits-veg-nuts..._100g	0.00	2.50	1.75	0.00	0.00

Tabel 6: Median tiap kolom gizi menurut label Nutri-Score.




Gambar 4: Sebaran kandungan gizi menurut label (outlier disembunyikan).

Ada dua pola yang terlihat di Tabel 6:

- **naik monoton:** energi, lemak, lemak jenuh, dan karbohidrat naik konsisten dari **a** ke **e**. Lemak jenuh misalnya naik dari median 0.5 g jadi 9.0 g, 18 kali lipat. Gula naik pelan dari **a** ke **d** (2.6 $\rightarrow$ 6.5) lalu melonjak tajam di **e** (28.65) — ini yang bikin korelasinya paling tinggi meski hubungannya jelas tidak linear.
- **tidak monoton:** garam naik dari **a** sampai **d** (0.10 $\rightarrow$ 0.75) tapi malah turun di **e** (0.26). Masuk akal, karena produk grade **e** didominasi makanan manis (gula tinggi, garam rendah), bukan makanan asin. Serat dan protein juga tidak turun rapi: paling tinggi di **a**, lalu naik-turun di grade tengah. Ketidakmonotonan inilah yang bikin korelasi keduanya kecil (≈ -0.13) padahal arahnya sudah benar.

5.8. Korelasi antar zat gizi

Kolom-kolom gizi juga saling berkorelasi. Ini penting diketahui sebelum dipakai sebagai fitur model: fitur yang sangat berkorelasi membawa informasi yang sama, sehingga salah satunya bisa dibuang.



Gambar 5: Korelasi Spearman antar zat gizi.

Pasangan paling kuat di Gambar 5: lemak–lemak jenuh (0.89), energi–lemak (0.83), energi–lemak jenuh (0.70), dan karbohidrat–gula (0.62). Kalau data ini nanti dipakai buat modeling, salah satu dari tiap pasangan itu bisa dibuang untuk menghindari multikolinearitas. Sebaliknya `salt_100g` hampir tidak berkorelasi dengan energi (0.05) maupun karbohidrat (0.03), jadi informasinya relatif mandiri.

Sebagai pemeriksaan, korelasi `grade_ordinal` dengan `nutriscore_score` bawaan API bernilai **+0.955**. Mendekati +1 karena grade memang diturunkan dari skor tersebut — bukan temuan baru, melainkan pemeriksaan bahwa data terunduh konsisten.

6. Kesimpulan

Hasil yang didapatkan: Lemak jenuh dan gula merupakan penentu terkuat label Nutri-Score, diikuti lemak total dan energi — arahnya positif, artinya makin tinggi kandungannya makin buruk labelnya.

Sebaliknya, protein dan serat berkorelasi negatif: keduanya memperbaiki label. Arah ini persis sesuai rumus resmi Nutri-Score, yang memberi poin penalti untuk energi, gula, lemak jenuh, dan garam, lalu poin pengurang untuk serat, protein, serta buah/sayur/kacang.

Kenapa nilainya tidak mendekati ± 1 ? Nutri-Score tidak menjumlahkan nutrisi secara linear, melainkan memetakan tiap nutrisi ke poin diskret lewat tabel ambang, lalu menjumlahkan poin-poin itu. Akibatnya tidak ada satu nutrisi pun yang bisa memprediksi label sendirian (label adalah hasil gabungan). Selain itu ambang poinnya berbeda untuk kategori khusus (minuman, lemak tambahan, keju), sementara sampel di sini mencampur semua kategori.

Catatan mutu dataset: `fiber_100g` hanya terisi sekitar 73%, paling rendah di antara semua kolom. Korelasinya dihitung dari sebagian data saja, jadi angkanya lebih lemah daripada kolom lain yang terisi di atas 94%.

Batasan sampel: Sampel dibuat berimbang per grade (400 produk tiap label), bukan acak dari populasi. Ini tepat untuk membandingkan antar grade, tetapi proporsi tiap grade di sini **tidak** mencerminkan komposisi asli basis data Open Food Facts.

7. Referensi

1. Open Food Facts. *API Documentation v2*. <https://openfoodfacts.github.io/openfoodfacts-server/api/>
2. Santé publique France. *Nutri-Score: Frequently Asked Questions*.
3. McKinney, W. (2022). *Python for Data Analysis*, 3rd ed. O'Reilly Media.