

LAPORAN PRAKTIKUM 1

Scraping Data dan Exploratory Data Analysis

Muhammad Irzam Hafis Fabiansyah (5054251024)

1. Tujuan

Praktikum ini mengambil data gizi produk pangan dari Open Food Facts lewat API resminya, membersihkannya, lalu menganalisisnya dengan EDA.

Pertanyaan yang dijawab: zat gizi apa yang paling menentukan sebuah produk mendapat label Nutri-Score **a** (terbaik) atau **e** (terburuk)?

2. Dasar teori

Open Food Facts adalah basis data produk pangan terbuka yang diisi sukarela oleh kontributor. Tiap produk bisa memiliki info gizi per 100 g dan label **Nutri-Score**, yaitu peringkat gizi lima tingkat dari **a** (paling sehat) sampai **e** (paling tidak sehat).

Nutri-Score dihitung dari skor gabungan: energi, gula, lemak jenuh, dan garam memberi poin penalti, sedangkan serat, protein, serta buah/sayur/kacang memberi poin pengurang. Tiap nutrisi tidak dijumlahkan begitu saja, melainkan dipetakan dulu ke poin diskret lewat tabel ambang.

Label Nutri-Score bersifat **ordinal**, urutannya jelas (**a** < **b** < **c** < **d** < **e**) tapi jaraknya tidak setara, jadi korelasi yang tepat adalah **Spearman**, yaitu korelasi Pearson yang dihitung atas peringkat data, bukan atas nilai aslinya:

$$\rho = 1 - \frac{6 \sum d_i^2}{n(n^2 - 1)}$$

dengan d_i selisih peringkat pasangan data ke- i dan n banyaknya data. Selain cocok untuk data ordinal, Spearman juga tahan terhadap sebaran miring dan pencilan — dua hal yang memang kelihatan di data gizi ini.

3. Alat dan bahan

Komponen	Keterangan
Bahasa	Python 3.13
Library	<code>requests</code> , <code>pandas</code> , <code>numpy</code> , <code>matplotlib</code>
Environment	Jupyter Notebook
Sumber data	Open Food Facts API v2 (<code>world.openfoodfacts.org/api/v2/search</code>)
Berkas kerja	<code>1_scraping.ipynb</code> , <code>2_eda.ipynb</code> , <code>data/off_nutrition.csv</code>

4. Langkah kerja

4.1. Scraping (1_scraping.ipynb)

Data diambil dari endpoint `search` dengan filter `nutrition_grades_tags` untuk tiap grade `a` – `e`. Tiap grade diambil 4 halaman berisi 100 produk, jadi target sampelnya $5 \times 4 \times 100 = 2000$ produk yang **berimbang per label**.

Kolom yang diminta ada dua kelompok: metadata (`code`, `product_name`, `brands`, `nutriscore_grade`, `nutriscore_score`, `nova_group`) dan sembilan kolom gizi per 100 g (energi, lemak, lemak jenuh, karbohidrat, gula, serat, protein, garam, dan estimasi buah/sayur/kacang).

Tiga hal teknis yang dipasang di tahap ini:

1. **retry berjenjang:** server Open Food Facts sering balas HTTP 503, jadi permintaan diulang sampai 8 kali dengan jeda yang membesar (`delay × percobaan`). Error permanen di luar 429/5xx langsung dilempar, tidak perlu diulang.
2. **cache berkas:** respons tiap halaman disimpan sebagai JSON di `data/raw/`, hasil akhirnya jadi `data/off_nutrition.csv`. Menjalankan ulang notebook karena itu tidak memicu permintaan jaringan lagi — hasilnya bisa direproduksi dan servernya tidak dibebani berulang kali.
3. **jeda antarpermintaan:** `time.sleep(delay)` di antara halaman, biar scraping-nya sopan.

Respons API menaruh semua angka gizi di dalam nested object `nutriments`, jadi tiap produk harus di-flatten dulu jadi satu baris datar sebelum dikumpulkan jadi `DataFrame`.

4.2. Pembersihan data (2_edu.ipynb)

Open Food Facts diisi sukarela oleh kontributor, jadi wajar ada nilai kosong, duplikat, dan angka mustahil (misalnya lemak 900 g per 100 g). Langkah pembersihannya:

1. **duplikat:** satu produk (`code`) bisa muncul di lebih dari satu halaman
2. **type data:** semua kolom gizi dipaksa numerik, teks yang gagal jadi `NaN`
3. **rentang wajar:** massa per 100 g tidak mungkin negatif atau melebihi 100 g, dan energi dibatasi 900 kkal (lemak murni ≈ 900 kkal/100 g). Nilai di luar itu kemungkinan besar salah input, bukan outlier asli, jadi dijadikan `NaN` karena kolom lain di baris yang sama masih berguna
4. **label:** `nutriscore_grade` dijadikan `Categorical` terurut, lalu diturunkan jadi `grade_ordinal` bernilai 1–5 (`a`=1 s.d. `e`=5, makin besar makin buruk) supaya bisa dikorelasikan

5. Hasil dan pembahasan

5.1. Gambaran umum dataset

Hasil scraping berukuran **1999 baris** $\times$ **15 kolom**: kurang satu dari target 2000 karena grade `e` hanya mengembalikan 399 produk unik. Setelah dibersihkan jumlah barisnya tetap 1999, artinya tidak ada duplikat `code` maupun label kosong, hanya bertambah kolom `grade_ordinal`. Sebaran labelnya praktis berimbang: 400 produk untuk `a–d` dan 399 untuk `e`.

Kolom gizi	Proporsi terisi
salt_100g	0.958
energy-kcal_100g	0.950
proteins_100g	0.949
fat_100g	0.949
sugars_100g	0.948
saturated-fat_100g	0.948
carbohydrates_100g	0.945
fruits-vegetables-nuts-estimate..._100g	0.879
fiber_100g	0.733

Tabel 1: Proporsi nilai terisi tiap kolom gizi setelah dibersihkan.

Delapan dari sembilan kolom terisi di atas 87%, tapi **fiber_100g** hanya 73.3% — paling jarang diisi kontributor.

5.2. Statistik deskriptif

Kolom	n	mean	std	Q1	median	Q3	maks
energy-kcal_100g	1899	300.26	209.49	98.51	289.00	456.00	900.0
fat_100g	1897	16.22	20.21	1.90	8.30	23.00	100.0
saturated-fat_100g	1895	5.45	8.38	0.40	1.70	7.20	60.0
carbohydrates_100g	1890	29.96	27.69	4.50	18.18	57.50	100.0
sugars_100g	1896	11.44	16.28	1.10	4.40	15.00	100.0
fiber_100g	1465	4.18	4.69	0.50	3.00	6.50	66.0
proteins_100g	1898	7.42	6.62	2.70	6.70	9.80	75.0
salt_100g	1916	0.66	1.61	0.03	0.30	0.95	44.6
fruits-veg-nuts..._100g	1757	13.73	26.22	0.00	0.00	13.00	100.0

Tabel 2: Statistik deskriptif kolom gizi (g per 100 g, kecuali energi dalam kkal).

Perhatikan jarak antara median dan rata-rata pada kolom seperti **sugars_100g** (mean 11.44 vs median 4.40) dan **salt_100g** (0.66 vs 0.30): kalau rata-rata jauh di atas median, sebarannya miring ke kanan — banyak produk berkadar rendah, sedikit produk berkadar sangat tinggi yang menarik rata-rata ke atas. Ini alasan utama memilih korelasi berbasis peringkat dan ringkasan berbasis median di bagian berikutnya.


5.3. Korelasi gizi dengan label

Tanda korelasi dibaca sebagai berikut:

- **positif** → makin tinggi kandungannya, makin buruk labelnya (bergerak ke **e**)
- **negatif** → makin tinggi kandungannya, makin baik labelnya (bergerak ke **a**)

Kolom gizi	Spearman	n	Arah
proteins_100g	-0.139	1898	memperbaiki label
fiber_100g	-0.122	1465	memperbaiki label
fruits-veg-nuts..._100g	-0.047	1757	memperbaiki label
salt_100g	+0.173	1916	memperburuk label
carbohydrates_100g	+0.233	1890	memperburuk label
fat_100g	+0.394	1897	memperburuk label
energy-kcal_100g	+0.397	1899	memperburuk label
saturated-fat_100g	+0.473	1895	memperburuk label
sugars_100g	+0.502	1896	memperburuk label

Tabel 3: Korelasi Spearman zat gizi terhadap `grade_ordinal` (`a`=1 s.d. `e`=5).



Gambar 1: Korelasi Spearman tiap zat gizi terhadap label. Merah memperburuk label, hijau memperbaiki.


Empat penentu terkuat ($|\text{Spearman}|$ terbesar) adalah gula (+0.502), lemak jenuh (+0.473), energi (+0.397), dan lemak total (+0.394). Sebaliknya protein (-0.139) dan serat (-0.122) berkorelasi negatif. Arah ini persis sesuai rumus resmi Nutri-Score di bagian dasar teori.

5.4. Bentuk hubungannya

Korelasi meringkas arah hubungan jadi satu angka. Tabel dan boxplot berikut menunjukkan bentuknya: apakah benar naik monoton dari `a` ke `e`, atau justru mendatar di grade tengah. Median dipakai, bukan rata-rata, karena alasan kemiringan sebaran tadi.

Kolom gizi (median)	a	b	c	d	e
jumlah produk	400	400	400	400	399
energy-kcal_100g	139.0	155.5	283.0	345.0	484.0
fat_100g	2.8	3.2	8.0	19.0	24.0
saturated-fat_100g	0.5	1.0	1.8	4.8	9.0
carbohydrates_100g	8.00	8.17	16.75	24.00	50.86
sugars_100g	2.60	2.30	4.50	6.50	28.65
fiber_100g	4.4	2.8	3.9	3.0	2.5
proteins_100g	9.70	5.40	7.00	6.95	6.00
salt_100g	0.10	0.18	0.49	0.75	0.26
fruits-veg-nuts..._100g	0.00	2.50	1.75	0.00	0.00

Tabel 4: Median tiap kolom gizi menurut label Nutri-Score.




Gambar 2: Sebaran kandungan gizi menurut label (outlier disembunyikan).

Ada dua pola yang kelihatan di Tabel 4:

- **naik monoton:** energi, lemak, lemak jenuh, dan karbohidrat naik konsisten dari **a** ke **e**. Lemak jenuh misalnya naik dari median 0.5 g jadi 9.0 g, 18 kali lipat. Gula naik pelan dari **a** ke **d** (2.6 → 6.5) lalu melonjak tajam di **e** (28.65) — ini yang bikin korelasinya paling tinggi meski hubungannya jelas tidak linear.
- **tidak monoton:** garam naik dari **a** sampai **d** (0.10 → 0.75) tapi malah turun di **e** (0.26). Masuk akal, karena produk grade **e** didominasi makanan manis (gula tinggi, garam rendah), bukan makanan asin. Serat dan protein juga tidak turun rapi: paling tinggi di **a**, lalu naik-turun di grade tengah. Ketidakmonotonan inilah yang bikin korelasi keduanya kecil (≈ -0.13) padahal arahnya sudah benar.

5.5. Korelasi antar zat gizi

Kolom-kolom gizi juga saling berkorelasi. Ini penting diketahui sebelum dipakai sebagai fitur model: fitur yang sangat berkorelasi membawa informasi yang sama, sehingga salah satunya bisa dibuang.



Gambar 3: Korelasi Spearman antar zat gizi.

Pasangan paling kuat di Gambar 3: lemak–lemak jenuh (0.89), energi–lemak (0.83), energi–lemak jenuh (0.70), dan karbohidrat–gula (0.62). Kalau data ini nanti dipakai buat modeling, salah satu dari tiap pasangan itu bisa dibuang untuk menghindari multikolinearitas. Sebaliknya `salt_100g` hampir tidak berkorelasi dengan energi (0.05) maupun karbohidrat (0.03), jadi informasinya relatif mandiri.

Sebagai pemeriksaan, korelasi `grade_ordinal` dengan `nutriscore_score` bawaan API bernilai **+0.955**. Mendekati +1 karena grade memang diturunkan dari skor tersebut — bukan temuan baru, melainkan pemeriksaan bahwa data terunduh konsisten.

6. Kesimpulan

Hasil yang didapatkan: Lemak jenuh dan gula merupakan penentu terkuat label Nutri-Score, diikuti lemak total dan energi — arahnya positif, artinya makin tinggi kandungannya makin buruk labelnya.

Sebaliknya, protein dan serat berkorelasi negatif: keduanya memperbaiki label. Arah ini persis sesuai rumus resmi Nutri-Score, yang memberi poin penalti untuk energi, gula, lemak jenuh, dan garam, lalu poin pengurang untuk serat, protein, serta buah/sayur/kacang.

Kenapa nilainya tidak mendekati ± 1 ? Nutri-Score tidak menjumlahkan nutrisi secara linear, melainkan memetakan tiap nutrisi ke poin diskret lewat tabel ambang, lalu menjumlahkan poin-poin itu. Akibatnya tidak ada satu nutrisi pun yang bisa memprediksi label sendirian (label adalah hasil gabungan). Selain itu ambang poinnya berbeda untuk kategori khusus (minuman, lemak tambahan, keju), sementara sampel di sini mencampur semua kategori.

Catatan mutu dataset: `fiber_100g` hanya terisi sekitar 73%, paling rendah di antara semua kolom. Korelasinya dihitung dari sebagian data saja, jadi angkanya lebih lemah daripada kolom lain yang terisi di atas 94%.

Batasan sampel: Sampel dibuat berimbang per grade (400 produk tiap label), bukan acak dari populasi. Ini tepat untuk membandingkan antar grade, tetapi proporsi tiap grade di sini **tidak** mencerminkan komposisi asli basis data Open Food Facts.

7. Referensi

1. Open Food Facts. *API Documentation v2*. <https://openfoodfacts.github.io/openfoodfacts-server/api/>
2. Santé publique France. *Nutri-Score: Frequently Asked Questions*.
3. McKinney, W. (2022). *Python for Data Analysis*, 3rd ed. O'Reilly Media.